

Projet d'Optimisation ML

Baila Dieng C12694

13 janvier 2026

Phase 1 : Fondements et Gradient Déterministe

On considère la fonction de perte logistique régularisée (Ridge) :

$$F(w) = \frac{1}{n} \sum_{i=1}^n \log(1 + e^{-y_i x_i^\top w}) + \frac{\lambda}{2} \|w\|_2^2, \quad w \in \mathbb{R}^d,$$

où $x_i \in \mathbb{R}^d$, $y_i \in \{-1, 1\}$ et $\lambda > 0$.

1. Analyse : Régularité et convexité

Classe $\mathcal{C}^2$. La fonction scalaire

$$\phi(t) = \log(1 + e^{-t})$$

est de classe $\mathcal{C}^2$ sur $\mathbb{R}$. La composée $\phi(y_i x_i^\top w)$ est donc de classe $\mathcal{C}^2$, et la somme finie + le terme de régularisation $\frac{\lambda}{2} \|w\|^2$ conservent cette régularité. Ainsi F est de classe $\mathcal{C}^2$ [?, ?].

Convexité. La fonction ϕ est convexe car

$$\phi''(t) = \frac{e^{-t}}{(1 + e^{-t})^2} \geq 0.$$

La composition d'une fonction convexe avec une application affine reste convexe. Donc F est convexe [?].

λ -forte convexité. Le terme $\frac{\lambda}{2} \|w\|^2$ est λ -fortement convexe. La somme d'une fonction convexe et d'une fonction λ -fortement convexe est λ -fortement convexe. Ainsi F est λ -fortement convexe.

2. Gradient et Lipschitzianité

Gradient.

$$\nabla F(w) = -\frac{1}{n} \sum_{i=1}^n \frac{y_i x_i}{1 + e^{y_i x_i^\top w}} + \lambda w$$

Hessien et Lipschitz.

$$\nabla^2 F(w) = \frac{1}{n} X^\top D(w) X + \lambda I_d, \quad D(w) = \text{diag} \left(\frac{e^{y_i x_i^\top w}}{(1 + e^{y_i x_i^\top w})^2} \right)$$

et

$$L = \frac{1}{4n} \|X\|_2^2 + \lambda.$$

3. Implémentation et comparaison

Descente de gradient à pas fixe :

$$w^{k+1} = w^k - \eta \nabla F(w^k)$$

Gradient conjugué : Converge plus rapidement que la descente de gradient, adapté aux fonctions quadratiques.

Comparaison :

- Descente de gradient : simple mais sensible au pas.
- Gradient conjugué : converge plus rapidement et sans réglage du pas.
- Pour des problèmes de grande dimension, le gradient conjugué est souvent préférable.




FIGURE 1 – Comparaison Descente de gradient vs Gradient conjugué

Phase 2 : Optimisateurs stochastiques




FIGURE 2 – Convergence SGD




FIGURE 3 – Convergence RMSProp

- SGD est bruité mais efficace pour de grands ensembles.
- RMSProp stabilise la convergence grâce à une adaptation automatique du pas.

Phase 3 : Méthodes proximales (ISTA / FISTA)

Pour la régularisation L1 (Lasso) :

$$L(w) = \frac{1}{n} \sum_{i=1}^n \log(1 + e^{-y_i x_i^\top w}) + \lambda \|w\|_1$$

ISTA :

$$w^{(k+1)} = \text{SoftThreshold}(w^{(k)} - \eta \nabla f(w^{(k)}), \eta \lambda)$$

avec

$$\text{SoftThreshold}(x, \alpha) = \text{sign}(x) \max(|x| - \alpha, 0)$$




FIGURE 4 – Convergence ISTA

FISTA :

$$t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2}, \quad z^{(k+1)} = w^{(k+1)} + \frac{t_k - 1}{t_{k+1}}(w^{(k+1)} - w^{(k)})$$




FIGURE 5 – Convergence FISTA

Conclusion

- Le gradient déterministe converge de manière régulière mais peut être lent.
- SGD est plus bruité mais permet un calcul plus rapide pour les grands ensembles.
- RMSProp stabilise la convergence avec une adaptation du pas.
- ISTA et FISTA permettent de traiter la régularisation L1 efficacement, FISTA étant plus rapide.
- Le gradient conjugué montre une convergence plus rapide que la descente de gradient simple.